Análisis de sentimientos y favorabilidad política en comentarios de Youtube durante las elecciones presidenciales peruanas de 2026

Jose Alva Cornejo Universidad Nacional de San Agustín de Arequipa, Arequipa, Perú

***Abstract*—La cuantificación computacional de la polarización política y el sentimiento ciudadano en redes sociales se ha concentrado predominantemente en Twitter/X y en contextos angloparlantes o europeos. Esta tendencia ha dejado una notable brecha de investigación en plataformas audiovisuales masivas como YouTube —donde el debate político en América Latina es prolífico y estructurado por líneas editoriales de canal—, agravada por dos limitaciones críticas: la incapacidad de los modelos de lenguaje generales para interpretar sociolectos locales (jerga informal, sarcasmo y regionalismos peruanos) y la omisión sistemática de medios de control neutrales para discernir entre la hostilidad partidaria y el descontento mediático generalizado. Para cerrar esta brecha, este trabajo propone un pipeline de aprendizaje profundo que analiza el sentimiento político y la polarización afectiva individual en comentarios de YouTube durante las elecciones presidenciales peruanas de 2026. Se recolectaron 552 456 comentarios públicos de 8 558 videos provenientes de 30 canales categorizados rigurosamente con fuentes citables en tres grupos: izquierda, derecha y un pool de control neutral. La clasificación de sentimientos se efectuó mediante RoBERTuito especializado en español peruano, a partir de cuyas inferencias se calcularon indicadores agregados de favorabilidad neta y ponderada por confianza probabilística, así como métricas de polarización afectiva individual (AP, AP_{In}, AP_{Out} y *spread*) adaptadas y extendidas a partir del marco de Martínez-España et al. Los hallazgos revelan una favorabilidad neta desfavorable en todos los bloques, acentuándose en los medios neutrales ($-0{,}510$). A nivel individual, el AP medio fue positivo en usuarios afines a la derecha ($1{,}484$) y negativo en la izquierda ($-0{,}259$), con un 74,58 % de usuarios categorizados como indeterminados. Estos resultados caracterizan la valencia discursiva en canales clasificados y evidencian la importancia de integrar controles de prensa neutral y modelos ajustados a dominios dialectales locales para el estudio de la polarización afectiva digital.**

***Index Terms*—Sentiment Analysis, Natural Language Processing, Deep Learning, Transformer Models, Slang, Social Media, Political Opinion Mining.**

I. Introducción

Las redes sociales se han consolidado como uno de los principales espacios para la discusión política y la expresión de opiniones ciudadanas. Plataformas como Facebook, Twitter/X y YouTube permiten que millones de usuarios compartan publicaciones, comentarios e interacciones relacionadas con acontecimientos políticos, generando grandes volúmenes de información que reflejan la percepción pública sobre candidatos, partidos y políticas gubernamentales [**?**]. YouTube, en particular, combina contenido audiovisual de formato largo con secciones de comentarios abiertas y una estructura basada en canales, lo que permite identificar el origen editorial de las publicaciones y analizar las reacciones de las audiencias de forma sistemática. Debido a su alcance e influencia, estas plataformas constituyen una fuente relevante para estudiar el comportamiento político y las tendencias de opinión mediante técnicas de procesamiento del lenguaje natural (Natural Language Processing, NLP) [**?**]. Además, la interacción con contenido político en redes sociales se ha relacionado con cambios en las actitudes de los usuarios. Afyare [**?**] encontró que un mayor nivel de involucramiento con contenido político se correlaciona con opiniones más polarizadas, destacando que estas plataformas pueden funcionar tanto como herramientas de movilización como canales de confrontación discursiva. En este contexto, el análisis automático del contenido generado por los usuarios constituye una alternativa indispensable frente a las limitaciones de costo, cobertura y temporalidad de las encuestas tradicionales.

Una de las principales soluciones computacionales empleadas para este problema es el análisis automático de sentimientos, mediante el cual se identifica la polaridad expresada en un texto y se clasifica generalmente como positiva, negativa o neutra. En años recientes, los avances en aprendizaje profundo y modelos basados en la arquitectura Transformer han permitido mejorar drásticamente el desempeño en clasificación textual al capturar dependencias contextuales complejas [**?**]. Estas técnicas han sido aplicadas específicamente al análisis de polarización política: Martínez-España et al. [**?**] propusieron una formulación pionera para cuantificar la polarización afectiva individual a partir de publicaciones en redes sociales; Bor et al. [**?**] midieron la polarización partidaria en Twitter según tópicos de política pública; y en el ámbito peruano, diversos trabajos han abordado elecciones previas mediante representaciones clásicas y modelos profundos [**?**], [**?**]. Asimismo, Ponte Torrel [**?**] documentó sentimientos polarizados en Twitter durante las elecciones peruanas de 2021, mientras que Mejía Navarrete [**?**] describió la intensificación histórica de la polarización política en el país entre 2000 y 2023.

A pesar de estos avances, la literatura contemporánea evidencia una marcada brecha de investigación. Por un lado, la gran mayoría de los marcos metodológicos para la medición de la polarización afectiva individual se ha diseñado exclusivamente para plataformas de microblogging como Twitter/X, caracterizadas por mensajes breves y crecientes barreras de acceso a datos tras cambios recientes en sus políticas de API [**?**]. Esta concentración ha dejado desatendidas plataformas audiovisuales masivas como YouTube, cuyo ecosistema de

debate comunitario en América Latina es prolífico y estructurado por líneas editoriales. Por otro lado, los modelos de lenguaje masivos preentrenados sobre corpus generales en español neutro o peninsular resultan insuficientes para capturar el lenguaje informal, la jerga política local (*slang*), el sarcasmo y los modismos característicos de las redes sociales peruanas [**?**], [**?**]. A ello se suma la omisión sistemática en estudios previos de un grupo de control periodístico neutral que permita distinguir entre la hostilidad partidaria y el desencanto generalizado de la ciudadanía frente a la cobertura de los medios tradicionales.

Para abordar esta brecha, el presente trabajo propone un pipeline de aprendizaje profundo que analiza el sentimiento político y la polarización afectiva individual a partir de 552 456 comentarios públicos de YouTube correspondientes a 8 558 videos de 30 canales curados editorialmente durante las elecciones presidenciales peruanas de 2026. Utilizando el modelo RoBERTuito especializado en español peruano, se clasifica la valencia textual de los comentarios y se calculan indicadores de favorabilidad agregada y polarización afectiva individual (AP, AP_{In}, AP_{Out} y *spread*).

Si bien este enfoque toma como punto de partida la formulación de polarización afectiva individual propuesta por Martínez-España et al. [**?**], introduce diferencias conceptuales y metodológicas sustanciales orientadas a superar sus limitaciones en entornos audiovisuales. En primer lugar, a diferencia del estudio de referencia, centrado en interacciones de Twitter/X dirigidas a 78 figuras políticas en una elección regional española, nuestro trabajo traslada el análisis a YouTube, donde las interacciones no son menciones directas sino comentarios situados bajo contenidos audiovisuales con líneas editoriales consolidadas, capturando discusiones comunitarias extensas a gran escala. En segundo lugar, se supera el empleo de modelos genéricos mediante la incorporación de *pyupeu/robertuito-peruvian-sentiment* [**?**], un modelo preentrenado sobre redes sociales y adaptado al contexto peruano que minimiza el error de clasificación ante la jerga y el registro coloquial electoral. En tercer lugar, mientras que el marco original segmenta a los actores únicamente en facciones partidistas sin grupo de control, nuestra propuesta incorpora un pool canónico de medios periodísticos neutrales como referencia basal, lo que permite evaluar si las interacciones exogrupales (AP_{Out}) responden a confrontación interpartidista o a un rechazo extendido hacia la prensa establecida. Finalmente, se complementa el esquema con una favorabilidad neta ponderada por la certidumbre probabilística del modelo clasificador (F_{pond}) y se delimita con rigurosidad estadística el conjunto de usuarios sin afinidad definida ($74{,}58\,\%$), evitando asignaciones ideológicas forzadas.

El resto del artículo se organiza de la siguiente manera. La Sección II presenta el estado del arte relacionado con el análisis de sentimientos y la polarización política computacional. La Sección III describe el método propuesto, detallando la adquisición y preprocesamiento de datos, el clasificador Transformer y la formulación matemática de las métricas. La Sección IV expone los resultados empíricos y su discusión metodológica. Finalmente, la Sección V presenta las conclusiones y el trabajo futuro.

II. Estado del Arte

El análisis de sentimientos aplicado al ámbito político ha adquirido una creciente relevancia debido al incremento del contenido generado por usuarios en redes sociales y a la disponibilidad de técnicas avanzadas de procesamiento del lenguaje natural. Las investigaciones recientes han abordado este problema desde diferentes perspectivas, incluyendo el estudio de la polarización política, la clasificación automática de opiniones y el desarrollo de modelos especializados para lenguaje informal.

Una de las principales líneas de investigación corresponde al análisis de la polarización política mediante técnicas de análisis de sentimientos. Martínez-España et al. [**?**] propusieron una metodología para medir la polarización afectiva individual utilizando modelos basados en Transformers sobre datos obtenidos de redes sociales. Su trabajo demostró que el análisis automático de sentimientos constituye una alternativa viable a los métodos tradicionales basados en encuestas para estudiar el comportamiento político. De forma similar, Bor et al. [**?**] emplearon análisis de sentimientos para cuantificar la polarización política en Twitter considerando distintos grupos políticos y diversas políticas públicas en Estados Unidos, evidenciando diferencias significativas en los niveles de polarización según el tema analizado.

Otra línea de investigación se ha enfocado en la clasificación automática de sentimientos políticos utilizando técnicas de aprendizaje automático y aprendizaje profundo. En el contexto peruano, Ayma et al. [**?**] analizaron mensajes publicados en Twitter/X durante las elecciones presidenciales de 2021 empleando representaciones textuales como TF-IDF y Word2Vec en combinación con algoritmos tradicionales de clasificación, obteniendo valores de F1-score superiores a 0.93. Posteriormente, Carrera et al. [**?**] compararon representaciones textuales tradicionales y modelos basados en Transformers para clasificar comentarios relacionados con proyectos de ley peruanos. Sus resultados mostraron que los modelos Transformer superaron consistentemente a los enfoques clásicos, alcanzando precisiones superiores al 88%.

Pandey et al. [**?**] analizaron el sentimiento de los votantes durante las elecciones legislativas de Bihar de 2025 utilizando más de 1 100 publicaciones obtenidas mediante la API de Twitter. Los autores compararon tres métodos de clasificación de sentimientos: Random Forest, Support Vector Machine (SVM) y el modelo basado en transformadores BERT. Inicialmente, las publicaciones fueron etiquetadas utilizando VADER y posteriormente se evaluaron las tendencias de cada partido político mediante el *Net Sentiment Score* (NSS). Los resultados mostraron que BERT obtuvo una exactitud del 80%, superando a los modelos tradicionales y evidenciando la capacidad de los modelos basados en transformadores para realizar análisis de sentimientos en escenarios electorales con conjuntos de datos de tamaño reducido.

Rizk et al. [**?**] propusieron un modelo para predecir los resultados de las elecciones presidenciales de Estados Unidos de 2020 utilizando publicaciones geolocalizadas de Twitter. La metodología combinó análisis de sentimientos, un clasificador Multinomial Naive Bayes y técnicas de aprendizaje automático para estimar tanto el voto popular como los votos del colegio electoral en los 50 estados. Además, los autores eliminaron publicaciones generadas por bots y valores atípicos, analizaron la evolución temporal y espacial de la opinión pública, y emplearon análisis de redes y detección de comunidades para identificar patrones de interacción entre los usuarios. Los resultados mostraron que el modelo predijo correctamente la victoria de Joe Biden, alcanzando una concordancia del 89.9% con los resultados oficiales de las elecciones.

Rodríguez-Ibáñez et al. [**?**] realizaron un estudio sobre el análisis de sentimientos en publicaciones de Twitter relacionadas con las elecciones presidenciales españolas de 2019. Los autores recopilaron miles de publicaciones realizadas antes y después del proceso electoral y propusieron una metodología basada en dos etapas: una caracterización estadística utilizando métricas como entropía, información mutua y el *Compounded Aggregated Positivity Index* (CAPI), seguida de la extracción de características mediante técnicas de aprendizaje no lineal, incluyendo autoencoders y métodos de incrustación estocástica. Los resultados mostraron que tanto las métricas estadísticas como las representaciones obtenidas permitieron caracterizar la evolución temporal del sentimiento y evidenciar diferencias en la polaridad entre los distintos partidos políticos y sus líderes durante el periodo electoral.

Chaudhry et al. [**?**] realizaron un análisis de sentimientos sobre publicaciones de Twitter relacionadas con las elecciones presidenciales de Estados Unidos de 2020, considerando el periodo previo, durante y posterior a los comicios. Para ello, construyeron un conjunto de datos utilizando la API de Twitter, aplicaron técnicas de preprocesamiento y extracción de características mediante TF-IDF, y emplearon un clasificador Naive Bayes para determinar la polaridad de los mensajes. Los autores compararon los resultados obtenidos con los resultados oficiales de las elecciones y analizaron el comportamiento de los estados disputados y de aquellos considerados atípicos. Los experimentos mostraron que el sentimiento expresado en Twitter coincidió con los resultados electorales en la mayoría de los casos, además de evidenciar cambios en la opinión pública antes y después de las elecciones. El clasificador alcanzó una exactitud del 94.58% y una precisión del 93.19%.

Más recientemente, diversos estudios han abordado la polarización y el análisis de sentimientos específicamente en YouTube. Miehling et al. [**?**] analizaron más de tres millones de comentarios de canales de noticias durante el conflicto Israel–Hamas utilizando análisis de sentimiento basado en aspectos, mostrando empíricamente que la valencia general de un comentario no necesariamente refleja la postura del autor hacia una entidad política específica. Este hallazgo es relevante para interpretar los resultados de modelos de clasificación de sentimiento general, como el empleado en el presente trabajo.

En conjunto, estos trabajos evidencian la efectividad de los modelos basados en Transformers para el análisis del discurso y el sentimiento político, pero revelan al mismo tiempo la marcada necesidad de extender estas metodologías hacia plataformas audiovisuales masivas como YouTube, incorporar controles de prensa neutral y adaptar las representaciones a la jerga y particularidades dialectales regionales.

III. Método Propuesto

La Figura 1 ilustra la arquitectura general del pipeline implementado, estructurado en cuatro etapas secuenciales: adquisición programática de datos mediante la API de YouTube Data v3, preprocesamiento y unificación con control editorial, inferencia de sentimiento con un modelo Transformer especializado en el contexto sociolingüístico peruano, y cómputo de métricas agregadas e individuales de favorabilidad y polarización afectiva.

A. Obtención de datos

Frente a las crecientes restricciones impuestas por plataformas como Facebook y Twitter/X para el acceso a datos con fines de investigación [**?**], se seleccionó YouTube como fuente primaria de información. YouTube ofrece acceso programático transparente a través de su API oficial y proporciona una estructura modular basada en canales, lo que permite asociar de forma directa y trazable el origen editorial de los contenidos audiovisuales con los comentarios vertidos por las audiencias.

Para el estudio del escenario electoral peruano de 2026, se definieron 30 canales de YouTube agrupados equitativamente en tres categorías: *izquierda* (10 canales), *derecha* (10 canales) y un pool de control *neutral* (10 canales). La asignación editorial de cada canal se fundamentó en fuentes externas verificables y citables, tales como reportes de propiedad mediática (Media Ownership Monitor), afiliación partidaria oficial y documentación periodística consolidada en Wikipedia en español. El grupo *neutral* agrupa medios de prensa tradicionales, cadenas estatales e iniciativas periodísticas sin afiliación partidaria expresa, funcionando como línea de base informativa.

Para cada canal se extrajeron los comentarios públicos de videos emitidos entre enero y junio de 2026, estableciendo un umbral máximo de 400 videos por canal y 2 000 comentarios por video para mitigar sesgos de sobrerrepresentación inducidos por viralidad aislada. En total, se recolectaron 552 456 comentarios públicos pertenecientes a 8 558 videos. Cabe destacar que la etiqueta de canal (*party*) asignada inicialmente a cada registro identifica exclusivamente la línea editorial de la fuente emisora y no la adscripción política del usuario que emite el comentario.

B. Preprocesamiento y unificación de datos

El preprocesamiento estandariza los registros y consolida los atributos necesarios para el modelado temporal, lingüístico y de interacción de usuarios. Para cada comentario c_i, se extrajeron diez atributos estructurados: el contenido textual, el identificador único del autor (user_id), el nombre de usuario, la cantidad de reacciones favorables (*likes*), el identificador

Algorithm 1 Preprocesamiento, estandarización y unificación del corpus

Require: Colección de archivos JSON $\mathcal{F} = \{F_k\}$, indexados por pool editorial $k \in \{\text{izq}, \text{der}, \text{neu_local}, \text{neu_canon}\}$.
Ensure: Conjunto unificado y desduplicado $\mathcal{D} = \{r_i\}$.

$\mathcal{D}_{\text{raw}} \leftarrow \emptyset$
for all archivo $F_k \in \mathcal{F}$ **do**
  Determinar la categoría editorial party $\leftarrow$ MapearPool(k)
  for all video $v \in F_k$ **do**
    for all comentario $c \in v$ **do**
      Extraer atributos: $\langle \text{texto}, \text{user_id}, \text{likes}, \text{fecha}, \text{respuestas}, \dots \rangle$
      Asignar etiqueta editorial party
      $\mathcal{D}_{\text{raw}} \leftarrow \mathcal{D}_{\text{raw}} \cup \{c\}$
    end for
  end for
end for
$\mathcal{D} \leftarrow \text{DeduplicarPorId}(\mathcal{D}_{\text{raw}}, \text{clave} = \text{comment_id})$
return $\mathcal{D}$

del comentario, el identificador y título del video de origen, el canal emisor, la fecha de publicación, el número de respuestas anidadas y la etiqueta editorial del canal emisor (party $\in \mathcal{J} = \{\text{izquierda}, \text{derecha}, \text{neutral}\}$).

En el caso del grupo neutral, se integró el pool recolectado localmente con el repositorio canónico de medios peruanos, aplicando una deduplicación estricta por identificador único de comentario (comment_id) para garantizar la unicidad de las interacciones. El procedimiento global de preprocesamiento se resume en el Algoritmo 1.

C. Clasificación de sentimientos con RoBERTuito especializado

Para mitigar la brecha de comprensión semántica propia de los modelos de lenguaje generales frente a la comunicación digital peruana, se empleó el modelo *pyupeu/robertuito-peruvian-sentiment* [**?**]. Este modelo parte de la arquitectura Transformer RoBERTuito [**?**], preentrenada sobre más de 500 millones de publicaciones de redes sociales en español, y fue sometido a un proceso de ajuste fino (*fine-tuning*) con corpus anotados de lenguaje informal y jerga política peruana.

Para cada comentario $c_i \in \mathcal{D}$, el modelo genera una distribución de probabilidades sobre el espacio triclase $\mathcal{S} = \{\text{negative}, \text{neutral}, \text{positive}\}$. Se selecciona la etiqueta con mayor verosimilitud S_i y se conserva su puntaje de confianza probabilística $P_i \in [0, 1]$:

$$(S_i, P_i) = f_{\text{RoBERTuito}}(c_i). \tag{1}$$

Ambos descriptores permiten no solo determinar la valencia predominante del texto, sino también modular el impacto de cada predicción en función de la certidumbre del clasificador.

D. Modelado de métricas de favorabilidad y polarización afectiva

Con el objetivo de caracterizar tanto la valencia agregada de los espacios discursivos como la polarización a nivel de usuarios individuales, se formularon dos niveles de análisis complementarios.

1) Favorabilidad neta y favorabilidad ponderada por certidumbre: A nivel agregado de cada categoría editorial $j \in \mathcal{J}$, se contabilizó el total de comentarios positivos (N_{pos}), negativos (N_{neg}) y neutrales (N_{neu}), con un volumen total $N = N_{\text{pos}} + N_{\text{neg}} + N_{\text{neu}}$. La favorabilidad neta (*Net Sentiment Score*, NSS) se define como:

$$F_{\text{neta}}(j) = \frac{N_{\text{pos}} - N_{\text{neg}}}{N} \in [-1, 1]. \tag{2}$$

Con el fin de evitar que predicciones de valencia marginales o con baja certidumbre distorsionen el indicador, se diseñó la favorabilidad neta ponderada por confianza (F_{pond}). Para cada comentario c_i, se asigna un signo de valencia $s_i \in \{+1\ (\text{pos}), 0\ (\text{neu}), -1\ (\text{neg})\}$, y su contribución se pondera por su confianza probabilística P_i:

$$F_{\text{pond}}(j) = \frac{1}{N} \sum_{i=1}^{N} s_i P_i \in [-1, 1]. \tag{3}$$

2) Indicador de polarización afectiva individual y spread: A diferencia de las métricas agregadas por canal, el indicador individual busca cuantificar el distanciamiento afectivo de los ciudadanos a partir de sus patrones de interacción, adaptando la formulación de Martínez-España et al. [**?**].

Para aislar a los usuarios políticamente activos con valencia definida, el universo de análisis individual se restringe a los usuarios que emitieron al menos un comentario clasificado como positivo o negativo ($S_i \in \{\text{positive}, \text{negative}\}$). Para cada usuario i y categoría de canal $j \in \mathcal{J} = \{\text{izquierda}, \text{derecha}, \text{neutral}\}$, se computa el conteo de interacciones positivas ($\text{Pos}_{i,j}$) y negativas ($\text{Neg}_{i,j}$).

La identificación del grupo de afinidad operacional (*ingroup*) se restringe estrictamente a los bloques políticos partidistas $\mathcal{J}_{\text{pol}} = \{\text{izquierda}, \text{derecha}\}$, excluyendo la categoría neutral de los posibles endogrupos. Sea $j^* = \text{argmax}_{j \in \mathcal{J}_{\text{pol}}}(\text{Pos}_{i,j})$:

$$\text{Ingroup}(i) = \begin{cases} j^*, & \text{si } j^* \text{ es único y } \text{Pos}_{i,j^*} > 0, \\ \text{Undetermined}, & \text{en empate o si } \text{Pos}_{i,j^*} = 0. \end{cases} \tag{4}$$

Para todo usuario con afinidad determinada $j = \text{Ingroup}(i)$, se calcula la polarización afectiva hacia su propio grupo (AP_{In}) como el balance de comentarios en su canal de afinidad:

$$\text{AP}(i)_{\text{In}} = \text{Pos}_{i,j} - \text{Neg}_{i,j}. \tag{5}$$

Por su parte, la polarización hacia los grupos externos (AP_{Out}) agrega el balance neto hacia todas las categorías restantes $\mathcal{J}_{\text{out}} = \mathcal{J} \setminus \{j\}$:

$$\text{AP}(i)_{\text{Out}} = \sum_{j' \in \mathcal{J} \setminus \{j\}} \left(\text{Pos}_{i,j'} - \text{Neg}_{i,j'} \right). \tag{6}$$

Es importante destacar que, en esta formulación, el conjunto $\mathcal{J} \setminus \{j\}$ contiene tanto al bloque político opuesto como a las fuentes periodísticas del pool neutral. Esta inclusión es metodológicamente coherente con el rol de los medios informativos en el ecosistema digital: los usuarios interactúan con coberturas neutrales para discutir la coyuntura, y computar su valencia en $\mathrm{AP}_{\mathrm{Out}}$ permite capturar si el distanciamiento exogrupal convive con un tono hostil o favorable hacia la prensa tradicional.

La polarización afectiva individual neta (AP) se obtiene como el contraste entre la adhesión endogrupal y la animosidad exogrupal:

$$\mathrm{AP}(i) = \mathrm{AP}(i)_{\mathrm{In}} - \mathrm{AP}(i)_{\mathrm{Out}}. \tag{7}$$

Puesto que $\mathrm{AP}(i)$ es una métrica acumulativa sensible a la hiperactividad de comentaristas frecuentes, se calcula en paralelo una versión normalizada (*spread*), adaptada de la formulación de dispersión de Wagner [**?**]:

$$\mathrm{spread}(i) = \sqrt{\frac{\sum_{j\in\mathcal{J}} \left(\mathrm{Pos}_{i,j} - \mathrm{Neg}_{i,j}\right)^2}{n_i}}, \tag{8}$$

donde el denominador $n_i = \sum_{j\in\mathcal{J}}(\mathrm{Pos}_{i,j}+\mathrm{Neg}_{i,j})$ representa el número total de interacciones del usuario i que presentaron valencia positiva o negativa. Nótese que, a diferencia de la propuesta original de Martínez-España et al. (que computa el total bruto de interacciones incluyendo neutrales), nuestro denominador restringe la normalización al volumen de intervenciones con valencia determinada, reflejando fielmente la intensidad afectiva efectiva.

Finalmente, siguiendo el criterio de corte empírico de la literatura, tanto $\mathrm{AP}(i)$ como $\mathrm{spread}(i)$ se clasifican en tres niveles discretos (*Bajo*, *Medio*, *Alto*) utilizando la media muestral (μ) y la desviación estándar (σ) del corpus:

$$\mathrm{Nivel}_{\mathrm{AP}}(i) = \begin{cases} \text{Bajo}, & \mathrm{AP}(i) < \mu_{\mathrm{AP}} - \sigma_{\mathrm{AP}}, \\ \text{Alto}, & \mathrm{AP}(i) > \mu_{\mathrm{AP}} + \sigma_{\mathrm{AP}}, \\ \text{Medio}, & \text{en otro caso;} \end{cases} \tag{9}$$

mientras que para el *spread*, por ser una magnitud estrictamente no negativa, se define nivel *Bajo* cuando $\mathrm{spread}(i) = 0$, nivel *Alto* cuando $\mathrm{spread}(i) > \mu_{\mathrm{spread}} + \sigma_{\mathrm{spread}}$ y nivel *Medio* en el intervalo intermedio. El procedimiento algorítmico global de polarización se sistematiza en el Algoritmo 2.

IV. Resultados e interpretación

Esta sección presenta los resultados de la clasificación de sentimiento y de las métricas calculadas sobre $552{,}456$ comentarios de videos publicados por fuentes agrupadas como izquierda, derecha y neutral. La etiqueta *party* identifica el grupo asignado a la fuente del video; no representa una etiqueta de sentimiento ni una clasificación política del autor del comentario.

Algorithm 2 Cómputo de polarización afectiva individual y *spread*

Require: Corpus clasificado $\mathcal{D} = \{(c_k, u_k, j_k, S_k, P_k)\}$, categorías $\mathcal{J} = \{\text{izq}, \text{der}, \text{neu}\}$, partidos $\mathcal{J}_{\mathrm{pol}} = \{\text{izq}, \text{der}\}$.
Ensure: Conjunto de métricas individuales $\mathcal{R} = \{\langle u, \text{Ingroup}, \mathrm{AP}_{\mathrm{In}}, \mathrm{AP}_{\mathrm{Out}}, \mathrm{AP}, \mathrm{spread}\rangle\}$.

```
Filtrar comentarios con valencia determinada: D_pol ← {c ∈ D | S_c ∈ {pos, neg}}
Extraer conjunto de usuarios evaluables: U ← UsuariosUnicos(D_pol)
Inicializar matrices de frecuencias Pos_{|U|×|J|} y Neg_{|U|×|J|}
for all comentario c = (u, j, S) ∈ D_pol do
    if S = pos then Pos[u, j] ← Pos[u, j] + 1
    else if S = neg then Neg[u, j] ← Neg[u, j] + 1
    end if
end for
for all usuario i ∈ U do
    n_i ← Σ_{j∈J}(Pos[i, j] + Neg[i, j])
    Determinar Ingroup(i) según Ecuación 4 sobre J_pol
    if Ingroup(i) ≠ Undetermined then
        j ← Ingroup(i)
        AP(i)_In ← Pos[i, j] − Neg[i, j]
        AP(i)_Out ← Σ_{j'∈J\{j}}(Pos[i, j'] − Neg[i, j'])
        AP(i) ← AP(i)_In − AP(i)_Out
        spread(i) ← sqrt((1/n_i) Σ_{j∈J}(Pos[i, j] − Neg[i, j])^2)
    else
        AP(i)_In, AP(i)_Out, AP(i), spread(i) ← NaN
    end if
end for
Calcular medias y desviaciones globales (μ_AP, σ_AP) y (μ_spread, σ_spread)
Asignar niveles discretos (Bajo, Medio, Alto) a los registros válidos
return R
```

A. Distribución de sentimiento y favorabilidad

La Tabla I resume el número de comentarios, la distribución de sentimiento y las medidas de favorabilidad por grupo de fuentes. La favorabilidad neta corresponde a la diferencia entre las proporciones de comentarios positivos y negativos. La medida ponderada normalizada incorpora los puntajes de confianza del modelo.

TABLE I: Sentimiento predicho y favorabilidad por grupo de fuentes.

Métrica	Derecha	Izquierda	Neutral
Comentarios	116,111	264,520	171,825
Negativo (%)	49.34	51.74	61.43
Neutro (%)	35.10	30.13	28.13
Positivo (%)	15.56	18.13	10.44
Favorabilidad neta	−0.338	−0.336	−0.510
Ponderada norm.	−0.281	−0.282	−0.422

En los tres grupos, el sentimiento negativo es la clase más frecuente. Las favorabilidades netas de las fuentes de derecha

e izquierda son prácticamente iguales (-0.338 y -0.336), mientras que el grupo neutral registra un valor más negativo (-0.510). La medida ponderada presenta el mismo orden. Estas diferencias describen la valencia general predicha en los comentarios recolectados; no demuestran que los comentarios estén dirigidos al grupo político asociado al canal ni que sus autores apoyen o rechacen ese grupo.

B. Polarización afectiva individual y spread

El análisis individual incluyó $135{,}259$ usuarios con al menos un comentario positivo o negativo. De ellos, $100{,}870$ (74.58%) quedaron como *Undetermined*: no tuvieron comentarios positivos en los grupos políticos considerados o empataron en su máximo. Por tanto, $34{,}389$ usuarios tuvieron un grupo de afinidad operacional determinado. Esta asignación se basa en el grupo con más comentarios positivos y no equivale a ideología declarada.

La Tabla II presenta los promedios por grupo asignado. AP se calcula como $\mathrm{AP_{In}} - \mathrm{AP_{Out}}$. El *spread* resume la magnitud normalizada de las diferencias entre comentarios positivos y negativos; su umbral de nivel alto en esta corrida fue 1.940.

TABLE II: Métricas individuales por grupo de afinidad operacional.

Métrica	Derecha	Izquierda
Usuarios	11,524	22,865
AP_{In} medio	0.493	-0.839
AP_{Out} medio	-0.991	-0.580
AP medio	1.484	-0.259
Spread medio	1.098	1.133
Spread alto (%)	7.12	10.21

Las Figuras 2–5 muestran distribuciones concentradas cerca de cero y colas con observaciones extremas para AP_{In}, AP_{Out} y AP; el *spread* es no negativo y se extiende hacia valores altos. En conjunto, las figuras muestran cómo se distribuyen los valores de polarización afectiva y dispersión entre los usuarios asignados a cada grupo durante el ciclo electoral peruano analizado.

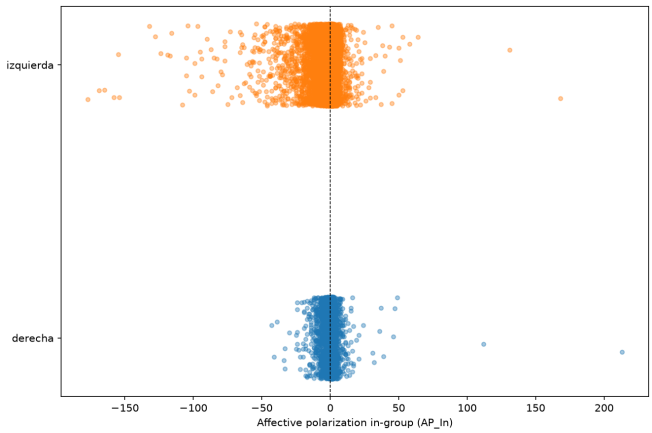


Fig. 2: Distribución individual de AP_{In} por grupo de afinidad operacional.

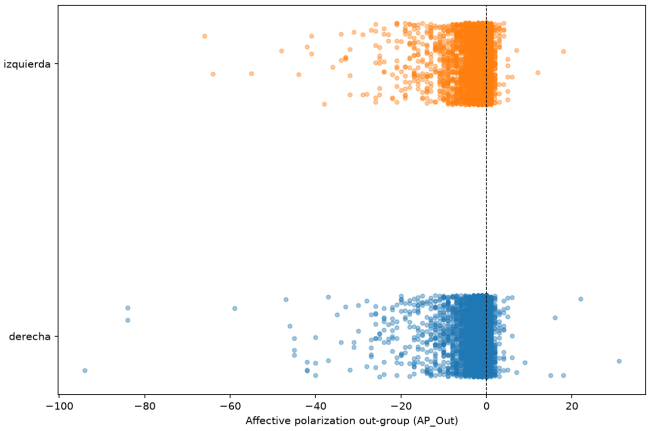


Fig. 3: Distribución individual de AP_{Out} por grupo de afinidad operacional.

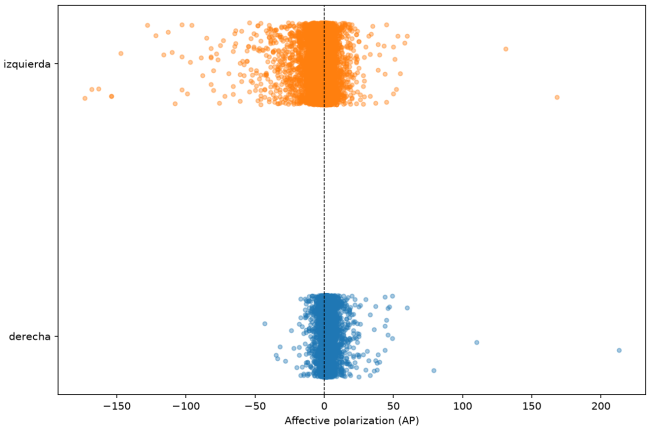


Fig. 4: Distribución individual de AP por grupo de afinidad operacional.

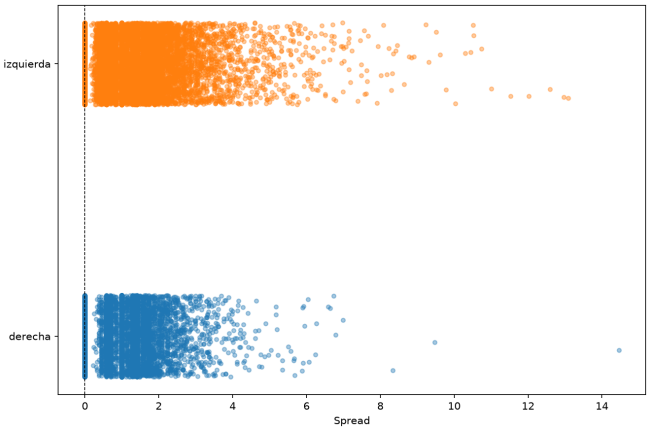


Fig. 5: Distribución individual de *spread* por grupo de afinidad operacional.

En la Figura 2, el promedio de AP_{In} es positivo para los usuarios asignados a derecha (0.493) y negativo para los

asignados a izquierda (-0.839). Descriptivamente, esto indica balances distintos de valencia bajo las fuentes asociadas a cada grupo: favorable en el primer caso y desfavorable en el segundo. La Figura 3 muestra promedios negativos de AP_{Out} en ambos grupos, con un valor más negativo para derecha (-0.991 frente a -0.580). Así, en esta corrida, el balance desfavorable de las interacciones externas estimadas aparece en ambos grupos, mientras que el balance interno distingue sus promedios.

La Figura 4 resume esa combinación: el AP medio es positivo para derecha (1.484) y ligeramente negativo para izquierda (-0.259), con una dispersión amplia y casos alejados de cero en ambas direcciones. Por su parte, la Figura 5 presenta promedios cercanos (1.098 para derecha y 1.133 para izquierda), aunque la proporción de nivel alto es mayor en izquierda (10.21% frente a 7.12%). Por tanto, el orden observado en AP no se repite en la proporción de *spread* alto; ambas métricas resumen aspectos distintos de la distribución.

El promedio global de AP fue 0.325 (DE 6.323) y el de *spread* fue 1.121 (DE 0.819). El análisis clasificó como indeterminados a 100,870 usuarios.

C. Comparación e interpretación de los resultados

Al comparar estos patrones con los de Martínez-España et al. [**?**], el AP_{In} medio del estudio de referencia (8.662 para la derecha y 6.813 para la izquierda) es positivo en ambos grupos; en esta corrida también es positivo para derecha (0.493), pero negativo para izquierda (-0.839). Los AP medios locales son 1.484 y -0.259, respectivamente, frente a valores aproximados de 9.885 y 7.972 derivados de las tablas del paper. AP_{Out} medio es negativo en ambos análisis: los valores aproximados del paper son -1.223 para la derecha y -1.160 para la izquierda, frente a -0.991 y -0.580 en esta corrida. La dirección del resultado coincide, pero las magnitudes difieren. En conjunto, estos patrones describen resultados distintos en las métricas observadas, pero no permiten concluir que una población presente más o menos polarización que la otra.

El *spread* medio local (1.098 para derecha y 1.133 para izquierda) y la proporción local de nivel alto (7.12% y 10.21%) también son inferiores a los valores reportados en el paper (1.874 y 1.748; 15.89% y 13.35%, respectivamente). Esta diferencia no constituye una comparación directa: el paper incluye cuatro grupos de Twitter y usa el total de interacciones como denominador de *spread*, mientras que este análisis incluye comentarios de YouTube clasificados por fuente, dos grupos políticos y un pool neutral, y cuenta solo comentarios positivos o negativos en ese denominador. También difieren las poblaciones, las unidades de análisis y los umbrales para definir niveles altos. Por ello, las magnitudes y proporciones no deben interpretarse como un ranking entre estudios ni como una réplica metodológica.

D. Limitaciones

Los balances de sentimiento predicho difieren entre los espacios de conversación asociados a izquierda y derecha y varían entre usuarios. Sin embargo, no permiten afirmar que los usuarios de derecha apoyen a su grupo, que los de izquierda lo rechacen ni que los valores negativos representen hostilidad hacia el campo opuesto. El modelo estima la valencia general del texto, no su postura hacia un objetivo político, y las métricas de conteo son sensibles al volumen de actividad. Además, el *spread* local usa como denominador solo comentarios positivos y negativos, por lo que excluye los neutrales. El universo de usuarios se forma tras filtrar esos comentarios y no incluye a quienes escribieron únicamente comentarios neutrales.

En conjunto, estos resultados caracterizan sentimiento predicho en los comentarios observados bajo las fuentes clasificadas y ofrecen métricas exploratorias de actividad por grupo. No permiten inferir directamente la postura de cada comentario hacia un actor político, la ideología de sus autores, la opinión de los votantes ni la polarización afectiva de la población peruana. Una interpretación más fuerte requeriría validar que la valencia esté dirigida al objetivo político y examinar la robustez de los patrones ante la cobertura desigual de canales y el volumen de comentarios.

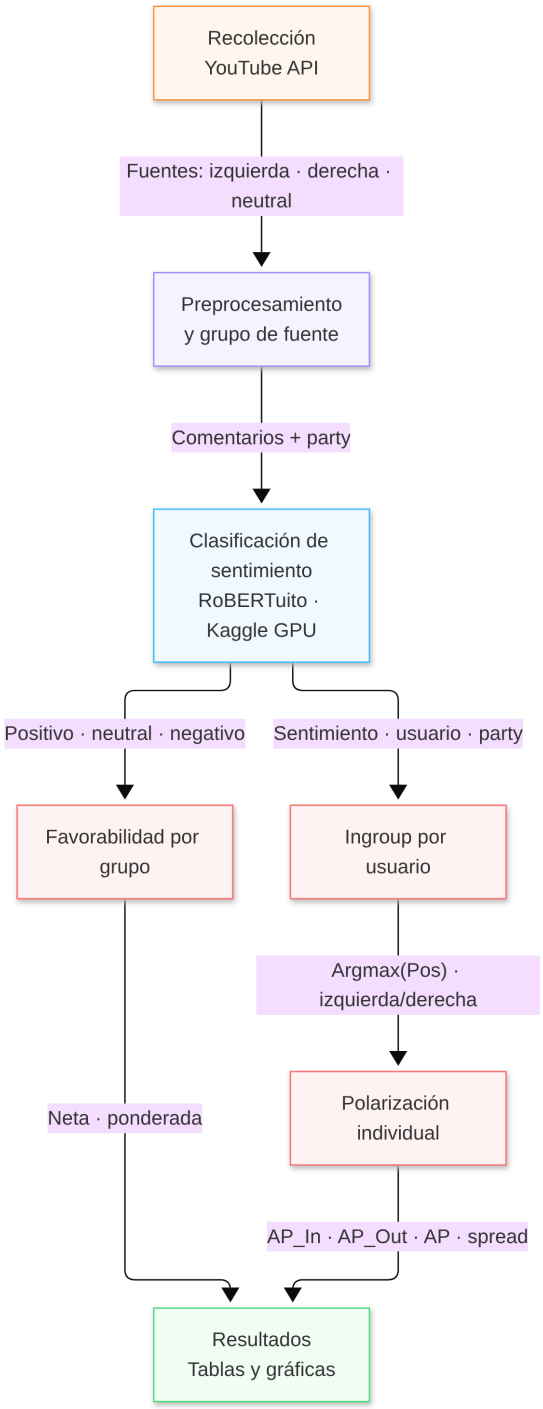


Fig. 1: Arquitectura general del pipeline propuesto para la recolección, inferencia de sentimiento y cálculo de métricas de polarización en YouTube.